

심층신경망 근사기반 조향 제어기

Approximation-based Steering Controller with Deep Neural Network

○유 명 석¹, 최 경 환^{1*}

¹⁾ 광주과학기술원 기계공학부 (TEL: 062-715-2413; E-mail: dding_98@gm.gist.ac.kr, khchoi@gist.ac.kr)

Abstract This paper introduces an approximation-based steering controller. The controller has three features: 1) Deep Neural Network (DNN) is employed as an approximator; 2) the stability of the controller is proven; 3) robustness of the controller is improved through some robust adaptive control techniques. The control policy in the controller is a type of feedback linearization control. Therefore, to cancel the system functions, the DNN approximates the unknown nonlinear system functions in the system dynamics. The adaptation laws for learning are derived using Lyapunov stability analysis. Using the analysis, the asymptotic convergence of the tracking error is guaranteed. Moreover, to prevent unpredictable parameter drift and chattering control around reference trajectory, ϵ -modification and dead-zone modification are used. A simulation study using CarMaker demonstrates that the controller improves performance by learning the system functions.

Keywords Approximation-based control, adaptive control, deep neural network (DNN), steering control

1. 서론

근사기반 제어는 적응 제어에 비해 보다 일반화된 제어 기법으로, 근사 이론을 통해 정보가 부족한 시스템 동역학 함수를 근사하여 제어기의 성능을 향상시킨다 [1]. 함수의 특성을 근사하기 때문에 제어 변수를 추정하는 기존 적응 제어 보다 제어기를 고차원적으로 향상시킬 수 있다. 여러 함수 근사기 중 대표적으로 신경망 함수와 퍼지 근사가 있다. 그중 신경망 함수의 경우 그 수학적 복잡성으로 인하여 단일 은닉층을 가진 신경망 함수를 많이 사용하였다. 하지만, 단일 은닉층의 신경망은 일반적으로 DNN에 비해 표현력과 학습 및 데이터 효율이 낮다고 알려져 있다. 최근 10 년 동안의 가파른 컴퓨터와 DNN의 발전에 더불어 DNN을 제어기 내부에 안정성을 보장하여 활용하는 것에 대한 관심이 집중되고 있다.

[2]의 저자는 성공적으로 적응(학습)법칙을 리아푸노프 안정성 분석으로부터 유도하였다. 특별히 sgn 함수와 projection modification을 이용하여 asymptotic 추적오차 수렴과 가중치의 boundedness를 증명하였다. 주로 복잡하다고 여겨지던 DNN의 안정성 분석을 완료함으로써 다양한 다른 신경망 모델의 제어기 사용을 위한 안정성 분석의 단초를 제공해 주었다는 것에 의미가 크다. 저자는 PINN과 LSTM 같은 신경망으로 확장 연구하였다.

본 논문에서는 control affine 시스템에 대하여 안정성을 보장하는 심층 신경망 기반 근사제어를 제안한다. 제안된 제어기의 asymptotic 추적 오차 수렴 또한 증명되었다. 마지막으로, 제어기는 CarMaker for Simulink를 통해 차량 조향 시스템에

적용 및 검증되었다.

2. 제어기 디자인

SISO control affine 시스템 (1)을 가정한다. $f(x)$ 와 $g(x)$ 는 알지 못하는 비선형 시스템 함수이다.

$$\dot{x} = f(x) + g(x)u \quad (1)$$

Universal approximation theorem [3]을 통해 $f(x)$ 와 $g(x)$ 는 (2)와 같이 연속하고 compact한 근사영역 $x \in D$ 내에서, 신경망 $\Phi_i(x_n; \theta_i), i \in [f, g]$ 을 통해 ϵ -정확도로 근사할 수 있다. x_n 은 신경망 입력 벡터이며, $\theta_i, i \in [f, g]$ 는 각 신경망의 가중치, 윗첨자 *는 가장 근사오차 $\epsilon_i, i \in [f, g]$ 이 작을 때의 가중치 임을 의미한다. 편의를 위하여 근사영역이 충분히 크다고 가정한다.

$$f(x) = \Phi_f(x; \theta_f^*) + \epsilon_f(x), \quad g(x) = \Phi_g(x; \theta_g^*) + \epsilon_g(x) \quad (2)$$

알 수 없는 변수들을 알고 있는 추정 변수로 대체하기 위하여 함수 $\Phi_i(y; \theta^*)$ 를 테일러 근사를 통해 (3)과 같이 표현한다. 신경망의 도함수 $\nabla_i \Phi_i$ 에 대한 수식은 [2]에 소개되어 있다. $\tilde{\theta}_i = \theta_i - \theta_i^*$ 는 가중치 오차이다.

$$\begin{aligned} \Phi_f(x; \theta_f^*) &= \Phi_f(x; \theta_f) - \nabla_{\theta_f} \Phi_f \tilde{\theta}_f + \text{H.O.T.} \\ \Phi_g(x; \theta_g^*) &= \Phi_g(x; \theta_g) - \nabla_{\theta_g} \Phi_g \tilde{\theta}_g + \text{H.O.T.} \end{aligned} \quad (3)$$

다음으로 제어입력을 feedback linearization 형태로 (4)와 같이 정의한다. $a_m \in R_{>0}$ 은 제어 변수이며, x_d 는 연속하는 desired 궤적, v_i 는 보조 제어 입력이다. $e = x - x_d$ 는 추적 오차이다.

$$u = \frac{1}{\Phi_g(x; \theta_f) + v_g} (-a_m e + \dot{x}_d - \Phi_f(x; \theta_f) - v_f) \quad (4)$$

리아푸노프 함수를 $V = \frac{1}{2}(e^2 + \tilde{\theta}_f^T \Gamma_f^{-1} \tilde{\theta}_f + \tilde{\theta}_g^T \Gamma_g^{-1} \tilde{\theta}_g)$ 로 정의한 후 도함수를 구하면 (5)와 같다. Positive definite 한 Γ_i 는 f, g 근사기의 적응률이다.

$$\begin{aligned} \dot{V} = & e \left(-a_m e + (\delta_f - v_f) + (\delta_g - v_g)u \right) \\ & + \tilde{\theta}_f^T \Gamma_f^{-1} \left[\dot{\hat{\theta}}_f - \Gamma_f \nabla_{\theta_f} \hat{f} e \right] + \tilde{\theta}_g^T \Gamma_g^{-1} \left[\dot{\hat{\theta}}_g - \Gamma_g \nabla_{\theta_g} \hat{g} e u \right] \end{aligned} \quad (5)$$

(5)를 통해 적응법칙을 (6)과 같이 얻을 수 있다.

$$\dot{\hat{\theta}}_f = \Gamma_f \nabla_{\theta_f} \Phi_f e, \quad \dot{\hat{\theta}}_g = \Gamma_g \nabla_{\theta_g} \Phi_g e u \quad (6)$$

또한 δ_i 에 대하여 v_i 를 통해 (7)과 같이 bounding control 을 하면 리아푸노프 함수의 도함수를 $\dot{V} \leq -a_m e^2$ 으로 만들 수 있고, 이는 근사영역 내에서 추적 오차가 exponentially 빠르게 수렴함을 나타낸다.

$$v_f = \begin{cases} +\hat{\delta}_f, & \text{if } e \geq 0 \\ -\hat{\delta}_f, & \text{if } e < 0 \end{cases}, \quad v_g = \begin{cases} +\hat{\delta}_g, & \text{if } eu \geq 0 \\ -\hat{\delta}_g, & \text{if } eu < 0 \end{cases} \quad (7)$$

추가적으로 예상치 못한 parameter drift 와 $e = 0$ 에서 chattering 를 방지하기 위하여 ϵ -modification 과 dead-zone 기법을 각각 사용하여 강인성을 부여하였다. 두 기법은 리아푸노프 안정성 분석 결과를 해치지 않는다 [1].

3. 실험

조향 제어기를 검증하기 위하여 Carmaker for Simulink를 이용하였다. 사용한 도로는 그림 1과 같이 짧은 직진 후 8자 도로를 반복하게 된다. 제어목적은 차량 중심부터 도로의 중앙선까지의 거리를 regulation 시키는 것이다. 차속은 30km이며 CarMaker에서 제공되는 종방향 제어가 바퀴의 토크를 자동 결정하며 제안 제어기는 조향각만 제어한다.




그림 1. 사용된 도로 환경

그림 2는 제안 제어기(ctrl1)와 비교군(ctrl2)과의 제어 결과를 보여준다. 비교 제어기로서 신경망 근사와 보조 제어 없는 $(\Phi_i, v_i = 0)$ P제어와 유사한 제어기를 선택하였다. 제어 결과, 제안 제어기는 제어함에 따라서 도로 중앙선까지의 거리를 줄여 나가는 것을 볼 수

있다. 이는 시스템 동역학을 학습의 결과로 볼 수 있다. 추가로, 이론과 달리 완전한 오차 수렴이 되지 않는데 이것은 강인성 부여로 인한 trade-off이다. 예를 들어, 초록 영역은 dead-zone으로 $(|e| < 0.05)$ 영역 내에서는 적응이 중지된다. 그로 인해 $e = 0$ 에서 민감하게 학습이 이루어지지 않는다.

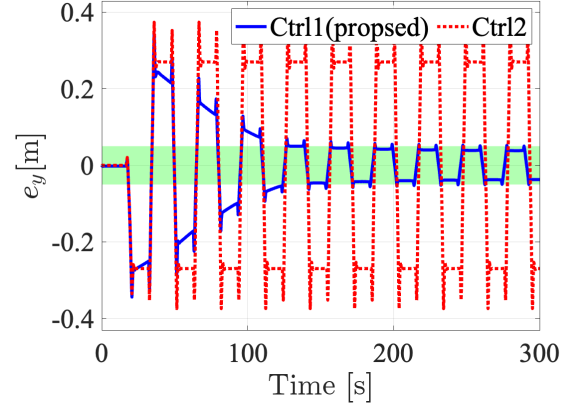


그림 2. 제어 결과; 중앙선까지의 차량 거리 (파란 실선: 제안 제어기, 빨간 점선: 비교 제어기)

4. 결론

본 논문에서는 신경망을 사용하는 근사기반 차량 조향 제어기를 소개하였다. 이론적으로 제어기의 안정성이 리아푸노프적으로 보장됨을 보였고, CarMaker for Simulink를 통한 시뮬레이션 검증으로 성능 개선을 확인하였다.

하지만, 실제 환경에서 사용하기 위해서는 여러 개선점들이 필요하다. 먼저, 튜닝 제어 변수가 많기 때문에 적절한 변수를 적절히 선정하는 것이 필요하다. 또한, 함수 g 를 근사하는 과정에서 u 의 분모가 singular 하게 근사가 되는 것을 방지하여야 한다. 이는 무한히 큰 제어입력을 초래하고 결국 포화되기 때문이다.

추후 연구로, 제약된 비선형 계획법을 통해 적응 법칙을 도출함으로써 튜닝 변수를 줄이고, 제약 조건을 만족하며 학습할 수 있도록 할 예정이다.

참고문헌

- [1] J. A. Farrell and M. M. Polycarpou, *Adaptive approximation based control: unifying neural, fuzzy and traditional adaptive approximation approaches*. John Wiley & Sons, 2006.
- [2] O. S. Patil, D. M. Le, M. L. Greene, and W. E. Dixon, "Lyapunov-derived control and adaptive update laws for inner and outer layer weights of a deep neural network," *IEEE Control Systems Letters*, vol. 6, pp. 1855-1860, 2021.
- [3] P. Kidger and T. Lyons, "Universal approximation with deep narrow networks," in *Conference on learning theory*, 2020: PMLR, pp. 2306-2327.