

동기전동기의 실시간 고정자 쇄교자속 추정을 위한 물리정보기반 학습 Physics-Informed Online Learning for Stator Flux Linkage Estimation in Synchronous Machines

○장 승 훈¹, 최 경 환^{1*}

¹한국과학기술원 조천식모빌리티대학원

(TEL: 042-450-1764; E-mail: shjang7071@kaist.ac.kr, kh.choi@kaist.ac.kr)

Abstract This paper presents a physics-informed online learning method that approximates the stator flux linkage model for synchronous machines (SMs) using neural networks (NNs). The approach trains the neural networks through optimization by minimizing the residuals of the governing equations of SMs, while considering the physical constraints inherent in the flux linkage model. The flux linkage obtained through the proposed method can be utilized to the state estimation or parameter identification for SMs. The proposed online learning method is verified through MATLAB simulation results obtained using a 35-kW IPMSM.

Keywords Physics-informed online learning, stator flux linkages, synchronous machines, estimation

1. 서론

동기기(Synchronous Machine)는 높은 효율, 출력 밀도, 그리고 정밀한 위치 제어가 가능하다는 장점을 갖는다. 이러한 성능은 토크 제어 성능에 크게 의존하며, 일반적으로 출력 토크는 고정자 쇄교자속과 전류의 함수로 표현된다. 따라서 쇄교자속을 실시간으로 추정할 수 있다면, 토크 제어 성능을 향상시킬 수 있게 된다.

본 논문에서는 물리정보기반 신경망 구조를 사용하여 실시간으로 동기기의 고정자 쇄교자속 모델을 학습을 통해 근사하는 방법을 제안한다. 제안된 방법은 동기기에 내재된 물리적 특성을 제약조건으로 표현하고, 이를 기반으로 최적화를 수행함으로써 신경망 학습을 진행한다. 이렇게 제안된 추정 방법은 Matlab/Simulink 35kW IPMSM 모델을 사용한 시뮬레이션으로 타당성을 검증한다.

2. 쇄교자속 학습 모델

2.1 동기기 모델의 편미분방정식(PDE) 기반 해석

동기 좌표계(d - q frame)에서 동기기의 쇄교자속에 대한 상미분방정식(ODE)들은 다음과 같이 편미분방정식(PDE)[1] 형태로 정리할 수 있다.

$$\begin{aligned} \frac{d\psi_s^d(i_s^d, i_s^q)}{dt} &= \frac{\partial \psi_s^d}{\partial i_s^d} \frac{di_s^d}{dt} + \frac{\partial \psi_s^d}{\partial i_s^q} \frac{di_s^q}{dt} = -R_s i_s^d + \omega_r \psi_s^q(i_s^d, i_s^q) + v_s^d \\ \frac{d\psi_s^q(i_s^d, i_s^q)}{dt} &= \frac{\partial \psi_s^q}{\partial i_s^d} \frac{di_s^d}{dt} + \frac{\partial \psi_s^q}{\partial i_s^q} \frac{di_s^q}{dt} = -R_s i_s^q - \omega_r \psi_s^d(i_s^d, i_s^q) + v_s^q \end{aligned} \quad (1)$$

여기서 $\psi_s^{d(q)}, i_s^{d(q)}, v_s^{d(q)}$ 는 각각 d - q 축에서의 고정자 쇄교자속, 전류 그리고 전압을 의미하며, R_s 와 ω_r 는 각각 고정자 저항과 전기적 각속도를 나타낸다. 식 (1)의 편미분 물리량인 $L_s^{dd(qq)}$ 와 $L_s^{dq(qd)}$ 들은 각각 자기(self) 및 상호(mutual) 미분(differential) 인덕턴스로 정의된다.

3. 쇄교자속 모델의 물리지식기반 온라인 학습

3.1 물리지식기반 신경망 구조

쇄교자속은 세 개의 층을 갖는 간단한 구조의 인공 신경망(Artificial Neural Network, ANN)을 통해 아래와 같이 근사할 수 있다.

$$\begin{aligned} \hat{\psi}_s^d(i_s^d, i_s^q) &= \hat{\mathbf{w}}_d^T \boldsymbol{\sigma}_d(i_s^d, i_s^q) \\ \hat{\psi}_s^q(i_s^d, i_s^q) &= \hat{\mathbf{w}}_q^T \boldsymbol{\sigma}_q(i_s^d, i_s^q) \end{aligned} \quad (2)$$

여기서 $\hat{\psi}_s^{d(q)}$ 는 신경망 기반 쇄교자속 근사치를, $\hat{\mathbf{w}}_d \in \mathbb{R}^m, \hat{\mathbf{w}}_q \in \mathbb{R}^n$ 는 추정된 가중치 벡터, 그리고

* 이 성과는 정부(과학기술정보통신부)의 재원으로 한국연구재단의 지원을 받아 수행된 연구임 (RS-2025-00554087).

$\sigma_d \in \mathbb{R}^m, \sigma_q \in \mathbb{R}^n$ 는 신경망 학습을 위한 활성화 함수 (activation function)를 나타낸다. 가중치 벡터는 일반적으로 신경망의 예측 값과 실제 값 간의 오차를 최소화 하도록 학습된다. 그러나 실제 쇄교자속을 직접 관측 할 수 없기 때문에, 식 (1)의 PDE를 지배방정식으로 정의하고 이를 잔차($e_s^{d(q)}$)로서 나타내면 다음과 같다.

$$\begin{aligned} e_s^d &= \hat{L}_s^d \frac{di_s^d}{dt} + \hat{L}_s^{dq} \frac{di_s^q}{dt} + R_s i_s^d - \omega_r \hat{\psi}_s^q - v_s^d \\ e_s^q &= \hat{L}_s^{qd} \frac{di_s^d}{dt} + \hat{L}_s^{qq} \frac{di_s^q}{dt} + R_s i_s^q - \omega_r \hat{\psi}_s^d - v_s^q \end{aligned} \quad (3)$$

식 (3)에서 $\hat{L}_s^{dd(qq)}$ 와 $\hat{L}_s^{dq(qd)}$ 는 각각 자기 및 순간 인덕턴스의 추정치를 나타내며, 식 (2)를 전류에 대한 편미분을 하여 해석적으로 계산된다.

3.2 최적화 문제 정의

가중치 학습을 위한 제약조건 기반 최적화 문제는 다음과 같이 구성된다.

$$\begin{aligned} \min_{\hat{\mathbf{w}}} J(\hat{\mathbf{w}}) &= \frac{1}{2} (e_s^d)^2 + \frac{1}{2} (e_s^q)^2 \\ \text{s.t.} \quad &\begin{cases} c_1^{\text{in}}(\hat{\mathbf{w}}) = \hat{L}_{dd}(\hat{\mathbf{w}}_d, i_s^d, i_s^q) - \bar{L}_{dd, \max} \leq 0 \\ c_2^{\text{in}}(\hat{\mathbf{w}}) = -\hat{L}_{dd}(\hat{\mathbf{w}}_d, i_s^d, i_s^q) + \bar{L}_{dd, \min} \leq 0 \\ c_3^{\text{in}}(\hat{\mathbf{w}}) = \hat{L}_{qq}(\hat{\mathbf{w}}_d, i_s^d, i_s^q) - \bar{L}_{qq, \max} \leq 0 \\ c_4^{\text{in}}(\hat{\mathbf{w}}) = -\hat{L}_{qq}(\hat{\mathbf{w}}_d, i_s^d, i_s^q) + \bar{L}_{qq, \min} \leq 0 \end{cases} \end{aligned} \quad (4)$$

식 (4)에서 J 는 목적함수, $\hat{\mathbf{w}} := (\hat{\mathbf{w}}_d^T, \hat{\mathbf{w}}_q^T) \in \mathbb{R}^{(m+n)}$ 는 가중치 벡터, $c_i^{\text{in}}, i \in I = \{1, 2, 3, 4\}$ 는 제약 조건들을 나타낸다. $\bar{L}_{dd(qq), \min}$ 와 $\bar{L}_{dd(qq), \max}$ 는 각각 자기 미분 인덕턴스의 최대값과 최소값을 의미하며, 이는 동기기에 물리적으로 내재된 제약 조건을 나타낸다. 이때, 목적함수 J 가 0에 수렴하도록 가중치를 최적화할 수 있다면, 식 (3)에서 지배방정식의 잔차 또한 최소화되어 쇄교자속을 신경망 학습을 통해 정확히 근사할 수 있다.

3.3 실시간 가중치 학습 방법

최종으로 식 (4)의 제약 조건 기반 최적화 문제의 해는 식 (5)와 같이 라그랑주 함수(L)를 정의하고 이에 따른 최적성에 대한 1차 필요 조건을 만족하도록 가중치 학습 방법 (6)을 적용하여 도출할 수 있다.

$$L(\hat{\mathbf{w}}, \lambda^{\text{in}}) := J(\hat{\mathbf{w}}) + \sum_{i=1}^4 \lambda_i^{\text{in}} c_i^{\text{in}} \quad (5)$$

$$\begin{aligned} \dot{\hat{\mathbf{w}}} &= -\alpha \frac{\partial L(\hat{\mathbf{w}}, \lambda^{\text{in}})}{\partial \hat{\mathbf{w}}} \\ \dot{\lambda}_i^{\text{in}} &= \beta_i^{\text{in}} c_i^{\text{in}}, \quad \lambda_i^{\text{in}} = \max(\lambda_i^{\text{in}}, 0) \end{aligned} \quad (6)$$

여기서 $\lambda^{\text{in}} := (\lambda_1^{\text{in}}, \lambda_2^{\text{in}}, \lambda_3^{\text{in}}, \lambda_4^{\text{in}})^T$ 은 제약 조건에 대한 라그랑주 승수 벡터, $\alpha, \beta_i^{\text{in}}$ 는 각각 가중치 및 라그랑주 승수의 학습률을 의미한다.

4. 시뮬레이션 검증

본 논문에서 제안하는 물리정보기반 자속 모델 학습 방법을 검증하기 위해 MATLAB Simulink 에서 제공하는 FEM 해석 기반 35kW IPMSM 시뮬레이션을 사용하였으며 사양 및 매개 변수는 표 1 과 같다.

표 1. IPMSM 사양.

Base Speed	DC voltage	Rated Torque
2000 [RPM]	325 [V]	180 [Nm]
Rated stator current	Pole pairs (P)	Stator resistance (R_s)
350 [A]	8	10.9 [mΩ]

그림 1 은 회전 좌표계에서 쇄교자속과 인덕턴스의 추정 결과를 보여준다. 그림 1(a)는 실제 쇄교자속과 추정치를, 그림 1(b)는 미분 인덕턴스와 제약 조건 활성화 시의 라그랑지 승수를 나타낸다. 제안된 학습 방법은 제약 조건 기반으로 최적화를 수행하여 신경망이 쇄교자속과 인덕턴스를 동시에 학습하므로 우수한 추정 성능을 보장한다.

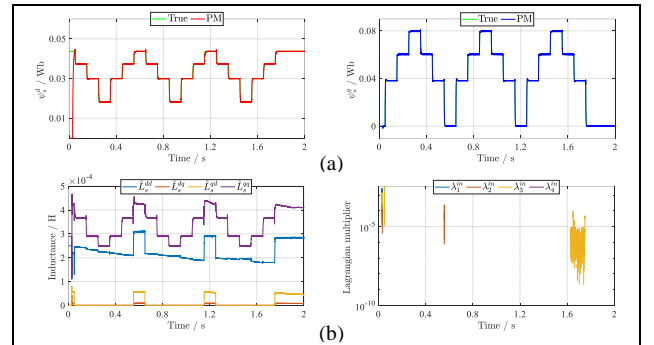


그림 1. (a) 회전 좌표계에서의 고정자 쇄교자속 추정치와 (b) 순간 인덕턴스 및 라그랑지 승수

5. 결론

본 논문은 물리정보기반 신경망 구조를 사용하여 실시간으로 동기기의 고정자 쇄교자속 모델을 학습하는 방법을 제안한다. 신경망 학습 과정은 물리 제약 조건을 포함한 최적화 문제를 통해 수행되며, 쇄교자속과 미분 인덕턴스를 동시에 학습하므로 향상된 추정 성능을 보장할 수 있다. 제안된 기법은 Matlab/Simulink 35kW IPMSM 시뮬레이션을 통해 제안하는 방법의 타당성을 입증하였다.

참고문헌

- [1] Hackl, Christoph M., et al. "Current control of reluctance synchronous machines with online adjustment of the controller parameters." 2016 IEEE 25th International Symposium on Industrial Electronics (ISIE). IEEE, 2016.